

# Inferencia Estadística y Reconocimiento de Patrones

UNaB, Lic. Cs. de Datos, 2021 cuat. 2

Sebastián Pedersen (sebastian.pedersen (at) unab (punto) edu (punto) ar)

# Clasificadores bayesianos, Discriminante lineal/cuadrático

(Clasificación supervisada)

# Recordatorio del problema de clasificación supervisada

1. Tengo datos de entrenamiento:  $(X_1, X_2, \dots, X_p) \rightarrow Y$ 
  - a.  $(X_1, \dots, X_p)$  son las variables, características o predictores (lo que mido)
  - b.  $Y$  es la clasificación, target, label o etiqueta.
  - c. Tengo muchos de estos datos (o la cantidad que pueda).
2. Con los datos de entrenamiento construyo mi modelo predictor/clasificador.
3. Con el modelo predictor clasifico nuevos datos  $(X_1, \dots, X_p)$ 
  - a. Ej.: (peso, altura, presión, cant. infartos)  $\rightarrow$  Sí/No riesgo cardíaco.
4. Queda en el tintero: ¿cómo evalúo a mi modelo predictor?
  - a. ¿Cómo mido qué tan bien está clasificando?
  - b. ¿De dónde saco datos nuevos para probarlo?
  - c. Si el dato es nuevo y por lo tanto no clasificado, ¿cómo sé si mi modelo anda bien o mal?

# Punto de vista Probabilidad/Estadística

- Intento predecir  $Y$  dados  $(X_1, \dots, X_p)$ 
  - (peso, altura, presión, cant. infartos)  $\rightarrow$  SÍ/NO con prob.  $p$ .
  - $(80, 170, 150, 2) \rightarrow$  SÍ con prob. 0.6
  - $(60, 155, 140, 1) \rightarrow$  NO con prob. 0.3
  - Etc.
- Es decir intento estimar  $P(Y=k \mid X_1, \dots, X_p=x_1, \dots, x_p)$  para  $k=0$  o  $1$  (o la cantidad de clases que haya).
- Una vez que tengo estimada esa probabilidad, pongo una regla para clasificar a los datos nuevos:

Por ejemplo si la estimación de  $P(Y=k \mid X_1, \dots, X_p=x_1, \dots, x_p) > 0.4 \rightarrow y=k$

O elijo el máximo sobre  $k$  de  $P(Y=k \mid X_1, \dots, X_p=x_1, \dots, x_p)$ , y clasifico según ese máximo. Por ejemplo para un problema con 3 clases:

- Estim. de  $P(Y=0 \mid X_1, \dots, X_p=x_1, \dots, x_p) = 0.3$
  - Estim. de  $P(Y=1 \mid X_1, \dots, X_p=x_1, \dots, x_p) = 0.2$
  - Estim. de  $P(Y=2 \mid X_1, \dots, X_p=x_1, \dots, x_p) = 0.5$
- } Clasifico como  $y=2$ .


# Cómo funciona un clasificador bayesiano

Primero transforma la probabilidad que quiere estimar de la siguiente forma:

$$P(Y = k|X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p|Y = k)P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

La anterior igualdad viene de aplicar esto:

$$P(Y|X) = \frac{P(Y \cap X)}{P(X)} = \frac{P(X|Y)P(Y)}{P(X)}$$

$$P(X|Y) = \frac{P(X \cap Y)}{P(Y)} \rightarrow P(X \cap Y) = P(X|Y)P(Y)$$


# Cómo funciona un clasificador bayesiano

Ahora usando esa transformación:

$$P(Y = k | X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p | Y = k) P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

Estima los valores del miembro derecho (para estimar el miembro izquierdo, que es el objetivo final). Es decir hay que estimar tres cosas:

- $P(Y=k)$
- $P(X_1, \dots, X_p = x_1, \dots, x_p)$
- $P(X_1, \dots, X_p = x_1, \dots, x_p | Y=k)$

$$P(Y = k | X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p | Y = k)P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

## Cómo funciona un clasificador bayesiano

1.  $P(Y=k)$  la estima por proporciones de los datos de entrenamiento: exactamente igual que para Bayes ingenuo.
2.  $P(X_1, \dots, X_p = x_1, \dots, x_p)$  se estima exactamente igual que para Bayes ingenuo, aunque para Discriminante Lineal/Cuadrático queda incluso más claro que no es necesaria esta estimación.
3. Para estimar  $P(X_1, \dots, X_p = x_1, \dots, x_p | Y=k)$  hay varias opciones:
  - a. Bayes ingenuo (naive Bayes)
  - b. **Discriminante Lineal o Cuadrático**
  - c. Otras.

$$P(Y = k | X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p | Y = k) P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

## Discriminante lineal / cuadrático

Para cada clase  $k$ , asume que el condicional resp. a la clase tiene distribución gaussiana. Pongo  $X = X_1, \dots, X_p$  para simplificar la notación:

$$P(X = x | Y = k) \sim N(\mu_k, \Sigma_k) \quad X | Y = k \sim N(\mu_k, \Sigma_k)$$

Por ejemplo para el caso de dos clases habría dos:

$$P(X = x | Y = 0) \sim N(\mu_0, \Sigma_0) \quad X | Y = 0 \sim N(\mu_0, \Sigma_0)$$

$$P(X = x | Y = 1) \sim N(\mu_1, \Sigma_1) \quad X | Y = 1 \sim N(\mu_1, \Sigma_1)$$



$$P(Y = k|X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p|Y = k)P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

## Discriminante lineal / cuadrático

Es decir para cada clase  $k$ , asume que puede calcular la prob. del condicional resp. a la clase por una gaussiana:

$$P(X = x|Y = k) = \frac{1}{(2\pi)^{p/2}|\Sigma_k|^{1/2}} e^{-\frac{1}{2}(x-\mu_k)^t \Sigma_k^{-1}(x-\mu_k)}$$

Para el caso de dos clases sería:

$$P(X = x|Y = 0) = \frac{1}{(2\pi)^{p/2}|\Sigma_0|^{1/2}} e^{-\frac{1}{2}(x-\mu_0)^t \Sigma_0^{-1}(x-\mu_0)}$$

$$P(X = x|Y = 1) = \frac{1}{(2\pi)^{p/2}|\Sigma_1|^{1/2}} e^{-\frac{1}{2}(x-\mu_1)^t \Sigma_1^{-1}(x-\mu_1)}$$

$$P(Y = k|X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p|Y = k)P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

## Discriminante lineal / cuadrático

Y luego para cada clase  $k$ , estima  $\mu$  y  $\Sigma$  a partir de los datos de entrenamiento (análogo a Bayes ingenuo), y aproxima la probabilidad anterior:

$$P(X = x|Y = k) = \frac{1}{(2\pi)^{p/2}|\Sigma_k|^{1/2}} e^{-\frac{1}{2}(x-\mu_k)^t \Sigma_k^{-1}(x-\mu_k)}$$

Por lo tanto para estimar  $P(Y = k|X = x) = \frac{P(X = x|Y = k)P(Y = k)}{P(X = x)}$

- $P(X=x | Y=k)$  la estima por la gaussiana, y a  $P(Y=k)$  y  $P(X=x)$  igual que en Bayes ingenuo.

$$P(Y = k|X_1, \dots, X_p = x_1, \dots, x_p) = \frac{P(X_1, \dots, X_p = x_1, \dots, x_p|Y = k)P(Y = k)}{P(X_1, \dots, X_p = x_1, \dots, x_p)}$$

## Discriminante lineal / cuadrático

Para cada clase  $k$ , estima  $\mu$  y  $\Sigma$  a partir de los datos de entrenamiento (análogo a Bayes ingenuo), y aproxima la probabilidad anterior:

$$P(X = x|Y = k) = \frac{1}{(2\pi)^{p/2}|\Sigma_k|^{1/2}} e^{-\frac{1}{2}(x-\mu_k)^t \Sigma_k^{-1}(x-\mu_k)}$$

- Discriminante lineal: asume  $\Sigma$  igual para todas las clases ( $k=0, 1, 2, \dots$ )
- Discriminante cuadrático: no asume que las  $\Sigma$  sean iguales.

# Discriminante lineal / cuadrático

$$P(Y = k|X = x) = \frac{P(X = x|Y = k)P(Y = k)}{P(X = x)}$$

Para estimar esta

Estima estas tres cosas.

Ahora dado un dato  $(X_1, \dots, X_p)$  puedo estimar la probabilidad de pertenecer a cada clase:

- Para  $k=0$  estim. una probabilidad
- Para  $k=1$  estim. una probabilidad, etc.

Y por ejemplo clasificar según la probabilidad más alta, o algún punto de corte adecuado.

# Referencias

- Hastie, Tibshirani, Introduction to Statistical Learning, secciones 4.4.1 a 4.4.3
- Bishop, Pattern Recognition and Machine Learning, sección 4.1
- Chan, Análisis Inteligente de Datos, secciones 9.1 y 9.2